

Kalman filter

Dr. Ing. Rodrigo Gonzalez

`rodrigo.gonzalez@ingenieria.uncuyo.edu.ar`

Control y Sistemas

Ingeniería Mecatrónica,
Facultad de Ingeniería,
Universidad Nacional de Cuyo

June 2021



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO

Es un algoritmo, más que un filtro

Es de los mayores desarrollos de ingeniería del siglo 20

State estimation

El filtro de Kalman es un estimador de estados (observador) que considera al sistema afectado por ruido De distribución gaussiana de media 0

Consider a linear time-invariant state-space model given by:

$$\dot{x} = Ax + Bu + v$$

v : ruido de proceso. Afecta el modelado

w : ruido de medición (sensores)

$$y = Cx + w$$

where x is the state (vector), u is the input or control signal and y is the output signal, v is the process disturbance and w is measurement noise. The disturbance v and the noise w are zero mean and Gaussian.

E: valor esperado

$$\mathbb{E}(v(s)v^T(t)) = R_v\delta(t-s)$$

R_v y R_w son muy importantes en el desarrollo del filtro

$$\mathbb{E}(w(s)w^T(t)) = R_w\delta(t-s)$$

where δ is the unit impulse function (dirac function).

Al considerar el ruido, x e y pasan de ser variables algebraicas a variables estocásticas
Esto se propaga entre las ecuaciones

State estimation

The state estimator (observer) is given as:

$$\dot{\hat{x}} = A\hat{x} + Bu + L(y - C\hat{x})$$

Expresión típica de observador en espacio de estado

The estimation error $\tilde{x} = x - \hat{x}$ can be computed as

$$\begin{aligned}\dot{\tilde{x}} &= \dot{x} - \dot{\hat{x}} = Ax + Bu + v - A\hat{x} - Bu - L(Cx + w - C\hat{x}) \\ &= (A - LC)\tilde{x} + v - Lw\end{aligned}$$

If $A - LC$ is stable, then the estimation error \tilde{x} is a stationary stochastic process.
 Propiedades estocásticas del error no van a cambiar tb es gaussiano

The covariance of the estimation error, $P_{\tilde{x}} = \mathbb{E}(\tilde{x}(t)\tilde{x}^T(t))$, is given by the following equation:
 $N \times N$ $N \times 1$ $1 \times N$

$$0 = (A - LC)P_{\tilde{x}} + P_{\tilde{x}}(A - LC)^T + R_v + LR_wL^T$$

The optimal observer minimizes $P_{\tilde{x}}$.
 Solo podemos modificar L. Lo demás viene por el sistema o la característica de sus ruidos

P_x es valor esperado de errores del vector de estado. En su diagonal estarán las varianzas de los estados del sistema. Fuera de esta son las var cruzadas (estado respecto al resto de los estados)

State estimation

The optimal observer gain, if the system is *observable*, is:

$$L = P_{\tilde{x}} C^T R_w^{-1} \quad \text{Observador óptimo}$$

where $P_{\tilde{x}} = P_{\tilde{x}}^T \geq 0$ is the solution to the Riccati equation:

$$0 = A P_{\tilde{x}} + P_{\tilde{x}} A^T + R_v - P_{\tilde{x}} C^T R_w^{-1} C P_{\tilde{x}}$$

The observer is called the **Kalman-Bucy filter**.

The Kalman-Bucy filter is:

- always stable. para sist observable
- *the optimal linear filter* for state estimation. (Para sistema lineal de ruido gaussiano)
- R_v and R_w are regarded as the design parameters.

R_v y R_w son matrices con las que vamos a ajustar el diseño del filtro de Kalman

Si R_v tiene valor alto, el diseñador no tiene confianza en su modelo(ruido)

Si R_w tiene valor alto, los sensores son ruidosos(el diseñador no confía en las mediciones)

Similarities with LQR:

LQR \leftrightarrow Kalman

$$A \leftrightarrow A^T \quad B \leftrightarrow C^T$$

$$S \leftrightarrow P \quad K \leftrightarrow L^T$$

$$Q_x \leftrightarrow R_v \quad Q_u \leftrightarrow R_w$$

Ambos algoritmos tratan de optimizar una f de costo.

LQR optimiza acciones de control o estados de un sist, y Kalman optimiza error entre estados verdaderos y estimados del sist.

Revisit Example - Vehicle steering (Ex 7.4)

Consider the following system:

$$\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} 0 & 12 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 6 \\ 3 \end{bmatrix} u + \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$


$$y = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + w$$

where x_1 is the lateral position Y , x_2 is the heading orientation θ and u is the steering angle δ .

The process disturbance and the measurement noise are zero mean with covariance

$$R_v = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad R_w = \rho$$

Design a Kalman filter to estimate the vehicle's states, from measurement of the lateral position.



Vehicle data: $v_0 = 12 \text{ m/s}$
 $a = 2 \text{ m}$
 $b = 4 \text{ m}$

Revisit Example - Vehicle steering (Ex 7.4)

State estimator:

$$\dot{\hat{x}} = A\hat{x} + Bu + L(y - C\hat{x})$$

The optimal observer gain, if the system is *observable*, is:

$$L = P_{\bar{x}} C^T R_w^{-1}$$

Buscamos P a partir del valor de ganancia óptima

where $P_{\bar{x}} = P_{\bar{x}}^T \geq 0$ is the solution to the Riccati equation:

$$0 = AP_{\bar{x}} + P_{\bar{x}}A^T + R_v - P_{\bar{x}}C^T R_w^{-1} C P_{\bar{x}} \quad P_{\bar{x}} = \begin{bmatrix} p_1 & p_2 \\ p_2 & p_3 \end{bmatrix}$$

The Riccati equation:

$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 12 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} p_1 & p_2 \\ p_2 & p_3 \end{bmatrix} + \begin{bmatrix} p_1 & p_2 \\ p_2 & p_3 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 12 & 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \rho^{-1} \begin{bmatrix} p_1 & p_2 \\ p_2 & p_3 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} p_1 & p_2 \\ p_2 & p_3 \end{bmatrix}$$

$$\rho = 1 \Rightarrow P_{\bar{x}} = \begin{bmatrix} 5.0 & 1.0 \\ 1.0 & 0.4167 \end{bmatrix} \Rightarrow L = \begin{bmatrix} 5.0 \\ 1.0 \end{bmatrix}$$



MATLAB:

```
[P,E,L]=care(A',C',[[1 0];[0 1]],1)
```

Con care resuelvo para sistema continuo la ec de riccati

Revisit Example - Vehicle steering (Ex 7.4)


Simulations using a sinusoidal input, with $x(0) = (5, 0.1)$ and $\hat{x}(0) = (0, 0)$:



Rápidamente sigue el valor del sistema

Revisit Example - Vehicle steering (Ex 7.4)

Simulations using a sinusoidal input, with $x(0) = (5, 0.1)$ and $\hat{x}(0) = (0, 0)$:



Al aumentar rho(ruido) el filtro tarda más en estimar valor de x_1 y x_2

State estimation – discrete time case

Consider a linear time-invariant state-space model in discrete time given by:

$$\begin{aligned}x[k+1] &= Ax[k] + Bu[k] + v[k] \\ y[k] &= Cx[k] + w[k]\end{aligned}$$

where x is the state (vector), u is the input or control signal and y is the output signal, v is the process disturbance and w is measurement noise. The disturbance v and the noise w are zero mean and Gaussian.

La derivada de x pasa a ser $x[k+1]$ porque predecimos en tiempo discreto el valor de x

The state estimator (observer) is given as:

$$\hat{x}[k+1] = A\hat{x}[k] + Bu[k] + L[k](y[k] - C\hat{x}[k])$$

and the estimation error $\tilde{x}[k] = x[k] - \hat{x}[k]$ can be computed as:

$$\tilde{x}[k+1] = (A - L[k]C)\tilde{x}[k] + v[k] - Lw[k]$$

Buscamos valor de L nuevamente

Ganancia del observador

State estimation – discrete time case

The covariance of the estimation error, $P_{\tilde{x}}[k] = \mathbb{E}(\tilde{x}[k]\tilde{x}^T[k])$, is given by:

$$P_{\tilde{x}}[k+1] = (A - L[k]C)P_{\tilde{x}}[k](A - L[k]C)^T + R_v + L[k]R_wL^T[k]$$

The observer gain that minimizes $P_{\tilde{x}}[k]$ is given by

$$L[k] = AP_{\tilde{x}}[k]C^T(R_w + CP_{\tilde{x}}[k]C^T)^{-1}$$

No podemos garantizar que la matriz a invertir sea diagonal.

This is the **discrete time Kalman filter**.

El parentesis puede causar problemas de estabilidad en el filtro de Kalman discreto

Para hallar P_{k+1} necesitas P_k

Note, that the Kalman filter is a recursive filter.

If $P_{\tilde{x}}[k]$ converges, then L is constant.

La convergencia depende de la estabilidad de la matriz entre paréntesis de más arriba

2 partes

F es la versión digitalizada de la matriz A

Predict

Predicted (*a priori*) state estimate

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

Predicted (*a priori*) estimate covariance

$$\mathbf{P}_{k|k-1} = \mathbf{F}_k \mathbf{P}_{k-1|k-1} \mathbf{F}_k^T + \mathbf{Q}_k$$

Q anteriormente era la matriz de covarianza Rv

Update

Innovation or measurement pre-fit residual

$$\tilde{\mathbf{y}}_k = \mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}$$

z contiene valores de sensores de salida

x predicho H antes era la matriz C

Innovation (or pre-fit residual) covariance

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k$$

R era Rv

Optimal Kalman gain

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T \mathbf{S}_k^{-1}$$

Updated (*a posteriori*) state estimate

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \tilde{\mathbf{y}}_k$$

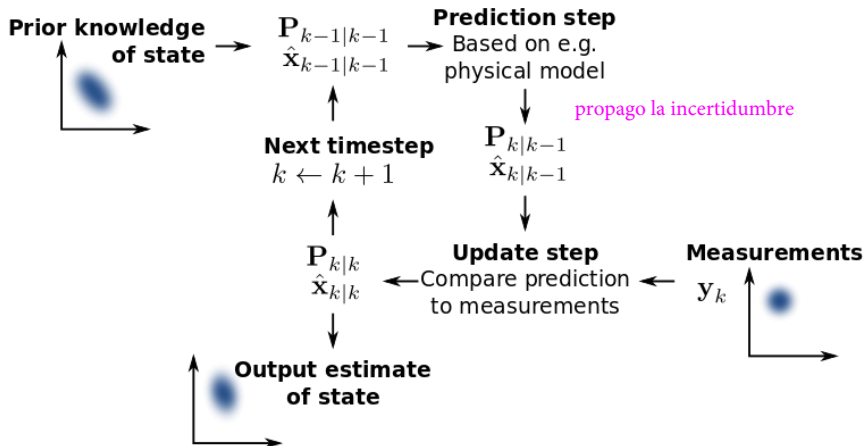
Este termino corrige el valor predicho del vector x

Updated (*a posteriori*) estimate covariance

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1}$$

Discrete Kalman Filter Algorithm

Distribuciones de probabilidad al ejecutar etapas de prediccion y update



La nueva distribución tiene reducida la incertidumbre al usar la técnica del filtro de Kalman

- Karl J. Astrom and Richard M. Murray *Feedback Systems*. Version v3.0i. Princeton University Press. September 2018. Chapter 8.
- Wikipedia. Kalman filter. https://en.wikipedia.org/wiki/Kalman_filter.